



IA y GOBERNANZA

EL ELEFANTE EN LA HABITACION

20
**"El mayor peligro de la Inteligencia Artificial, con diferencia, es ...
que las personas concluyan demasiado pronto que la entienden"**

Eliezer Yudkowsky

Así empezó todo



Alan Turing (1936)



Isaac Asimov (1941)



Frank Rosenblatt: Perceptrón 1958

**ELIZA Emulator**

A 1966-style chatbot demo + explainer

1966 Primer ChatBot

Talk to ELIZA online

ELIZA is a classic 1966 program that simulates conversation using pattern matching and transformation rules. This modern browser-based ELIZA emulator recreates that style in a clean retro terminal, while the rest of the site explains how it works, why it felt persuasive, and why it still matters in AI history.

What it is

A historical-style chatbot demo you can try instantly, plus a plain-English explainer site.

What it isn't

Not "AI" in the modern sense; no real understanding, memory, diagnosis, or reasoning.

[Learn how ELIZA works](#)[Why it felt so real](#)<https://elizachatbot.com/>


What is ELIZA?

1) Detect keywords

ELIZA looks for patterns such as "mother", "feel", "because", or "I can't", then picks the first strong rule that matches.

2) Transform your words

It swaps pronouns and perspective markers so your input can be turned back into a plausible question or prompt.



Privacy note: by default
anywhere.

[ELIZA] SYSTEM ONLINE

GOOD DAY. I AM ELIZA. HOW CAN I HELP YOU TODAY?

> |TYPE YOUR RESPONSE...

[BURN RECORDS](#)[TRANSMIT](#)

Y aquí vinieron las primeras sorpresas



Kasparov vs Deep Blue (1997)




Lee Sedol vs AlphaGo (2016)


Paridad humana:

cuando se iguala la tasa de error media de una destreza cognitiva.

Los algoritmos
están vacíos.
Los modelos no.




Time to adoption the technology: 100M users




¿Qué hicimos?

- **CONECTAMOS TODO** → Y llegó el malware
- **ABRIMOS INTERNET** → Y después llegaron los FW
- **ACCESO REMOTO** → Y tuvimos que montar MFA




¿CUAL ES EL FUTURO DE LA INTELIGENCIA ARTIFICIAL?




NO TENEMOS NI IDEA

Conceptos de IA



Machine Learning



Deep Learning



Neural Network



Generative Models



Supervised Learning



Computer Vision




LLM




NLP




Bayesian Learning



Transformers



ChatBot




AI Assistant




AI Agent

Una comparativa



ChatBot





AI Assistant



AI Agent

Nivel de inteligencia	básico	medio	alto
Aprendizaje automático	Muy limitado o ninguno	Aprende Patrones	Aprende y se adapta
Interacción principal	Conversación simple	Diálogo con conversación avanzada	Objetivo general con autonomía
Capacidad de decisión	Nula	Limitada	Alta
Ejecuta tareas	Solo Instrucciones directas	Tareas ‘simples’ bajo pedido	Múltiples tareas sin supervisión
Ejemplo típico	Chat de atención al cliente	Siri, Alexa, ChatGPT	CoPilots de trabajo

Pero aún hay más: MCP, A2A, ACP



El espejismo de la IA: Alta adopción, alto fracaso

85%



Tasa de fracaso de proyectos de IA por problemas de gobernanza y calidad de datos (Gartner).

60%



Proyectos que serán **abandonados** en 2026 por falta de datos listos.

35%



Organizaciones con **políticas sólidas de gobernanza de IA**.

13%




Empresas que ya reportan **vulneraciones de seguridad** vinculadas a modelos de IA.

La pregunta ya no es si usar IA, sino si su empresa está estructuralmente preparada para integrarla sin comprometer el negocio.


Uno de los errores más frecuentes:

Asumir que la discusión sobre la calidad del dato es una discusión técnica.

- Un dato real mantiene una correspondencia con aquello que pretende describir (ámbito de la verdad).
- Un dato **completo** incorpora todos los elementos necesarios para que esa descripción resulte suficiente (ámbito de la comprensión).



- **Un dato aislado difícilmente puede considerarse verdaderamente real.**
 - Puede ser exacto
 - Puede ser verificable
 - Puede superar todos los controles de calidad
- Pero si carece del contexto necesario para interpretar su significado, sigue siendo una representación parcial del fenómeno que pretendemos describir.




Ex: PRECISIÓN vs EXACTITUD



PRECISO

EXACTO


Las mediciones están cerca del valor verdadero y cerca unas de otras.



PRECISO

INEXACTO


Las mediciones están cerca unas de otras pero no del valor verdadero.



IMPRECISO

EXACTO

Las mediciones están cerca del valor verdadero pero no están cerca unas de otras.



IMPRECISO

INEXACTO

Las mediciones no están cerca del valor verdadero ni cerca unas de otras.

6 DIMENSIONES DE LA CALIDAD DE LOS DATOS




Exactitud

El grado con el que el dato representa correctamente la entidad o atributo que está describiendo




Completitud

El porcentaje de los datos que faltan en el Data-Set considerado




Consistencia

la ausencia de diferencias o contradicciones en los datos, independientemente de la fuente de los mismos.




Validez

Los datos inválidos afectan a la precisión y completitud de un data set



Integridad

Muestra la validez de las relaciones entre varias entidades de datos



Unicidad

Asegura que las duplicidades o los datos superpuestos están identificados y marcados

No es igual para todos



Organizaciones INMADURAS

- Sufren por la falta de datos



Organizaciones INTERMEDIAS

- Sufren por la sobreabundancia de datos



Organizaciones MADURAS

- Comprenden que el verdadero valor reside en la capacidad de distinguir qué contexto es esencial y cuál es accesorio.

La SOLUCIÓN

¿Pon una IA en tu vida?



RESIDUOS
RECICLABLES



IA



VALOR
GENERADO



El principio inquebrantable: Garbage In, Garbage Out

Datos Tóxicos


-  Datos duplicados, sesgados o desactualizados
-  Silos de información sin visión transversal

Resultado: Alucinaciones, discriminación algorítmica y decisiones erróneas.

Datos Gobernados

-  Calidad cuantificada, trazabilidad y categorización


Resultado: IA precisa, útil y alineada con los objetivos de negocio.



El error fundamental de Diagnóstico

Tratar la IA como un problema de software, no organizacional

Problema Técnico (El Enfoque Antiguo)



- **Naturaleza:** Soluciones conocidas.
- **Acción:** Comprar, instalar, encender, finalizar.
- **Responsabilidad:** Delegable a perfiles puramente técnicos.

Desafío Adaptativo (La Realidad de la IA)



- **Naturaleza:** La definición del problema muta constantemente.
- **Acción:** Aprender, evolucionar, cambiar comportamientos.
- **Responsabilidad:** Capacidad organizacional transversal permanente.

LLM Challenges



Las respuestas son tan buenas como lo sean los **datos de entrenamiento**


Carecen de “Sentido común”



No siempre lo hacen bien, porque no siempre pueden comprender el **contexto**, lo que lleva a respuestas inapropiadas o simplemente incorrectas.



No pueden “desaprender”
No pueden olvidar



Una vez que el modelo establece relaciones **NO** hay una forma sencilla de hacer que el modelo ignore alguna parte de lo que ha aprendido.



Sujetos a **SESGOS**

Cualquier sesgo presente en los datos de entrenamiento puede a menudo estar presente en las respuestas




Sufren **Alucinaciones**.

Cuando perciben patrones u objetos inexistentes creando outputs que no tienen sentido o son completamente erróneos.



Las Aplicaciones son Algoritmos codificados → **DETERMINISTAS**
Diseñadas a partir de análisis de datos y resultados definidos
Comprobable por regresión



El conjunto de relaciones estadísticas es muy complejo
La precisión nunca se puede garantizar
Demasiada **VARIABILIDAD**. No se puede reducir con reguladores.



Implantar un agente de IA se parece mucho al proceso de contratar a una persona.

Hay que darle contexto,
Explicarle cómo trabajas,
Enseñarle los procesos,


...

Y decirle dónde tiene que encontrar la información.

La inteligencia artificial es una herramienta
extraordinaria.

Pero no sustituye la madurez operativa.
Es una capa que se construye encima de ella.
(o mejor dicho: en paralelo).





LOS ERRORES QUE NO PODEMOS VOLVER A COMETER

¿Cómo lo vamos a hacer?


- ¿QUÉ DATOS VAMOS A CONSUMIR?
- ¿QUÉ PERMISOS TIENE?
- ¿CÓMO SE AUDITA?
- ¿CÓMO SE REVOKA?
- ¿CÓMO SE MONITORIZA?




¿Qué arriesgamos?

- ACCESO TRASVERSAL A LA INFORMACIÓN
- CORRELACIÓN MASIVA DE DATOS
- AMPLIFICACIÓN DE ERRORES HUMANOS
- VELOCIDAD SIN PRECEDENTES

DISEÑO DEL MODELO DE GESTION DE LOS DATOS



EL MODELADO DE AMENAZAS



Entender el sistema



Identificar las amenazas



Analizar las vulnerabilidades




Proponer medidas preventivas



Revisión y Actualización

- Se crean **diagramas** para identificar los componentes, flujos de información y los límites de confianza.
 - Se identifican todos los **puntos de entrada** (debilidades) por los que los sistemas externos pueden interactuar.
 - Se determina qué activos, datos o funciones son valiosos y deben protegerse.
 - Considerar los **posibles abusos** del atacante.
- OWASP**
- STRIDE
 - LINDDUN
 - VAST
 - TRIKE
 - MITRE ATLAS
- Identificar y describir las amenazas que pueden afectar al sistema.
- Revisar el modelo de amenazas periódicamente para adaptarlo a los cambios en el sistema.
- Proponer medidas preventivas para evitar introducir nuevas vulnerabilidades.
- Visualizar las amenazas como diagramas jerárquicos para comprender sus posibles rutas → **Arboles de amenazas**
- Evaluación de riesgos**



LLM01: 2025 Prompt Injection LLM01:2025 Prompt Injection A Prompt Injection Vulnerability occurs when user prompts alter the... Read More	LLM02: 2025 Sensitive Information Disclosure LLM02:2025 Sensitive Information Disclosure Sensitive information can affect both the LLM and its application... Read More	LLM03: 2025 Supply Chain LLM03:2025 Supply Chain LLM supply chains are susceptible to various vulnerabilities, which can... Read More	LLM04: 2025 Data and Model Poisoning LLM04:2025 Data and Model Poisoning Data poisoning occurs when pre-training, fine-tuning, or embedding data is... Read More	LLM05: 2025 Improper Output Handling LLM05:2025 Improper Output Handling Improper Output Handling refers specifically to insufficient validation, sanitization, and... Read More
LLM06: 2025 Excessive Agency LLM06:2025 Excessive Agency An LLM-based system is often granted a degree of agency... Read More	LLM07: 2025 System Prompt Leakage LLM07:2025 System Prompt Leakage The system prompt leakage vulnerability in LLMs refers to the... Read More	LLM08: 2025 Vector and Embedding Weaknesses LLM08:2025 Vector and Embedding Weaknesses Vectors and embeddings vulnerabilities present significant security risks in systems... Read More	LLM09: 2025 Misinformation LLM09:2025 Misinformation Misinformation from LLMs poses a core vulnerability for applications relying... Read More	LLM10: 2025 Unbounded Consumption LLM10:2025 Unbounded Consumption Unbounded Consumption refers to the process where a Large Language... Read More

12 controles esenciales de seguridad para Agentes de IA



Gestión de identidades y privilegios



Acceso a herramientas en tiempo real.



Protección frente a Prompt Injection.



Protección de salidas y datos.



Control de acciones basado en riesgo



Human-in-the-Loop para acciones críticas.



Ejecución en entornos aislados.



Gestión segura de memoria.



Aislamiento entre agentes.



Monitorización del comportamiento.




Red Teaming específico



Seguridad de la cadena de suministro

ULTIMAS CONSIDERACIONES



SISTEMAS > DATOS > DECISIONES

An elephant is standing in a room with light-colored walls and a wooden floor. A large window on the right side of the room shows a view of a city street with buildings. The elephant is facing away from the camera, towards the window.

MUCHAS GRACIAS



@Emilio_RR



Emilio Rico Ruiz

trc